Relatório de Arquitetura
Módulo de Anonimização Jurídica

Preservação de Coerência Processual em Documentos Judiciais
Projeto PIDE / FAPESPA — iSACI

Versão do relatório: 1.0 — 16 de outubro de 2026

Base documental: ADRs 0000–0012 (com emendas de 16/10/2026), especificação técnica, arquitetura interativa v1.3

Status: arquitetura validada no papel + provas N1 executadas

Sumário

1. Sumário executivo
2. Contexto e problema
3. Visão geral da arquitetura
4. Decisões arquiteturais (ADRs 0000–0012)
5. Arquitetura de segurança
6. Validação — provas executadas e resultados
7. Riscos e limitações honestas
8. Trabalho restante e roadmap
9. Inventário documental

1. Sumário executivo

Este relatório consolida o estado da arquitetura do módulo de anonimização de documentos judiciais com preservação de coerência processual, projetado como **nó soberano edge por organização** — sem dependência de nuvem em runtime — exposto via API REST/OpenAPI, com NLP determinístico e localmente hospedado, mapeamentos cifrados por caso e trilha de auditoria à prova de adulteração.

O desenho foi registrado em 13 decisões arquiteturais (ADRs 0000–0012), passou por revisão de segurança em 16/10/2026 que fechou 11 lacunas (documentadas como emendas), e teve suas premissas mecânicas testadas em **7 provas arquiteturais (spikes) — todas aprovadas**: latência de inferência, isolamento de rede, motor simbólico de correferência, trilha de auditoria, esquema criptográfico do cofre, normalização anti-evasão e autenticação offline.

> **Veredito:** a arquitetura está **validada no papel e em princípio** para todos os mecanismos determinísticos e de infraestrutura. O que falta não é desenho nem prova de conceito — é execução da trilha científica (corpus → métricas) e validação institucional no órgão, ambas previstas no roadmap.

Dimensão	Estado	Evidência
Coerência do desenho	VALIDADO	13 ADRs + especificação + v1.3 consistentes
Segurança (desenho)	REVISADO	11 lacunas fechadas por emendas em 16/10
Mecanismos (spikes)	7/7 PROVADOS	relatório em `spikes/P1-P7_resultado.md`
Baseline de métricas	MEDIDO	P8: harness + corpus v0 — §6.1
Métricas científicas (corpus real)	PENDENTE	depende de corpus (Etapa 3+)
Validação institucional	PENDENTE	Etapa 11, no órgão

2. Contexto e problema

Documentos judiciais contêm dados pessoais e sensíveis cuja divulgação irrestrita é vedada (LGPD; art. 189 do CPC — sigilo para menores, segredo de justiça; Resolução CNJ 615/2025). Anonimizar "na unha" destrói a utilidade: nomes substituídos de forma inconsistente quebram a compreensão de quem é parte, quem testemunhou, quem é parente de quem e em que ordem os fatos ocorreram.

O módulo resolve essa tensão com duas propriedades inseparáveis:

- **Proteção**: anonimização irreversível ou pseudonimização reversível sob chave — nenhum dado em claro persiste fora do documento original.
- **Coerência processual**: toda menção ao mesmo sujeito recebe o mesmo pseudônimo *dentro do mesmo processo*; papéis processuais (autor, ré, testemunha), relações (parentesco, hierarquia) e cronologia são preservados.

Restrições do domínio que moldaram todas as decisões: operação em rede isolada do órgão (soberania), auditabilidade verificável (evidence-grade), nenhuma IA generativa (determinismo exigido para revisão jurídica), e métricas de privacidade/utilidade pré-registradas.

3. Visão geral da arquitetura

3.1 Pipeline (12 estágios)

```
documento
  → 0. normalização Unicode (NFKC + invisíveis + homoglifos + traços)
  → 1. idempotência (hash do documento)
  → 2. guardrails (prompt-injection dual-pass + pseudo-perplexidade)
  → 3. ingestão/OCR-aware
  → 4. detecção híbrida de entidades
       ├─ legal-BERT NER (fine-tunado no tagset próprio)
       ├─ regex + validadores (CPF, RG, OAB, CNJ…)
       └─ gazetteers
  → 5. janelamento (512 tokens, overlap) + merge de spans
  → 6. correferência — motor simbólico Linked Entities
  → 7. classificador de papel processual
  → 8. modelo de relações (parentesco, hierarquia, temporal)
  → 9. política de pseudônimos por caso
  → 10. substituição + trilha de auditoria
  → 11. verificação residual (re-scan detector independente)
  → saída: documento anonimizado + risk_score + review_flags
```

3.2 Dois modos, um cofre

	Anonimização	Pseudonimização
Reversibilidade	**Irreversível** — destruição cerimonial da chave HMAC do caso (ADR-0012)	Reversível — mapeamento cifrado AES-GCM, DEK por caso
Pseudônimo	consistência por caso via `HMAC(entidade ‖ case_id)`	idem + mapeamento legível no cofre

Caso de uso	publicidade, dados abertos	compartilhamento com reversão autorizada (break-glass)

3.3 Soberania

Nó edge autocontido por organização: imagem OCI única + Docker Compose (api, nginx, Postgres, Vault) sobre redes `internal: true` — **egress deny-all por ausência de rota** (provado, §6-P2). A única superfície externa é o nginx com TLS 1.3 + mTLS. Modelos de NLP viajam assinados na imagem (`safetensors` only), sem download em runtime.

4. Decisões arquiteturais (ADRs)

ADR	Decisão	Por quê / alternativa descartada
0000	Regra de maturidade 3 anos	stack só com componentes ≥3 anos estáveis — nó do setor público não é lugar de tecnologia quente
0001	Detecção híbrida: BERT-legal NER + regex/validadores + gazetteers	NER puro falha em identificadores estruturados; regex puro falha em contexto; híbrido cobre os dois modos de falha
0002	Correferência por motor simbólico "Linked Entities"	determinístico = auditável e explicável (exigência jurídica); redes de correferência neural não são verificáveis item a item. **Risco: cobertura do long tail — spike P3 avaliou: plausível**
0003	FastAPI + OpenAPI gerada de código	contrato testável por Schemathesis; async para o batch; sync no path de docs pequenos
0004	Postgres: cofre de mapeamentos + trilha hash-chained **com âncora externa**	*emenda 16/10*: HMAC agora `HMAC(e‖case_id)` — antes correlacionava entidade entre casos; âncora externa obrigatória — sem ela, rewrite total da trilha era indetectável (provado em P4)
0005	Vault Transit: KEK no Vault, DEK por caso (envelope)	banco sozinho não abre nada; Vault sozinho não tem os dados — separação dados↔chaves
0006	OIDC/JWT validado offline via JWKS cacheado; **RFC 8705 + TTL curto obrigatórios**	*emenda 16/10*: sem introspecção possível (isolamento), token vazado só vence por TTL — por isso minutos, e cert-bound para não ser portável
0007	Rede isolada: VLAN + egress deny-all + túneis de suporte	*emenda 16/10*: deny-all cobre DNS e IPv6 (canais de exfiltração); API não binda host; ciclo de vida de cert mTLS via CA interna
0008	Empacotamento: imagem OCI única + Compose	*emenda 16/10*: política safetensors-only (peso de modelo não é código executável); hardening baseline — rootfs read-only, cap_drop ALL, no-new-privileges, não-root, seccomp
0009	Toolchain TDD: pytest + hypothesis + schemathesis + syft/grype	*emenda 16/10*: grype adicionado como gate de CVE sobre o SBOM — inventário sem varredura não é controle
0010	Verificação residual + escore de confiança	re-scan com detector de erro independente; risco zero é inatingível — mede-se e sinaliza-se o residual (`risk_score` , `review_flags` , `needs_review`)
0011	Zero IA generativa	encoders discriminativos apenas; elimina classes inteiras de vulnerabilidade (instrução embutida, memorização regurgitável);

		pseudo-perplexidade via masked-LM preserva o detector
0012	**NOVO** — Ciclo de vida de chaves	unseal Shamir distribuído por papéis (ninguém destranca sozinho); bootstrap secret-zero via arquivo montado; destruição cerimonial de chave HMAC por caso = o evento que materializa a irreversibilidade

5. Arquitetura de segurança

5.1 Anéis concêntricos

Anel	Controle	Estado
Rede	egress deny-all por ausência de rota (`internal:true`), DNS sem upstream, IPv6, binding restrito — só nginx expõe	**PROVADO (P2)**
Transporte	TLS 1.3 + mTLS no nginx; CRL/vida-curta para revogação em isolamento	**desenho; implantação**
Identidade	OIDC offline via JWKS cache; RFC 8705 cert-bound; TTL em minutos	**PROVADO (P7, JWT)**
Dados	AES-GCM por caso (Vault Transit), HMAC por caso, banco não decifra nada	**PROVADO (P5)**
Integridade	hash-chain + âncora externa assinada; pgaudit; audit devices do Vault	**PROVADO (P4)**
Pipeline	guardrails + estágio-0 Unicode + supressão conservadora + re-scan independente	**PROVADO (P6, parcial)**

5.2 Invariantes de implementação

- **Payload nunca persiste**: nem em logs, nem em temporários, core dumps (`ulimit -c 0`), respostas de erro ou trilha — a trilha guarda hashes, não conteúdo.
- **Erros não ecoam documento**: validação (Pydantic) sanitizada — um 400 não vaza PII.
- **Budget de trabalho**: limites de bytes E de tokens/janelas (413 nos dois) — documento gigante não vira DoS por requisição.
- **Erro no lado seguro**: over-suppression > under-suppression; não-vincular > vincular errado — sistemático em todo o desenho.

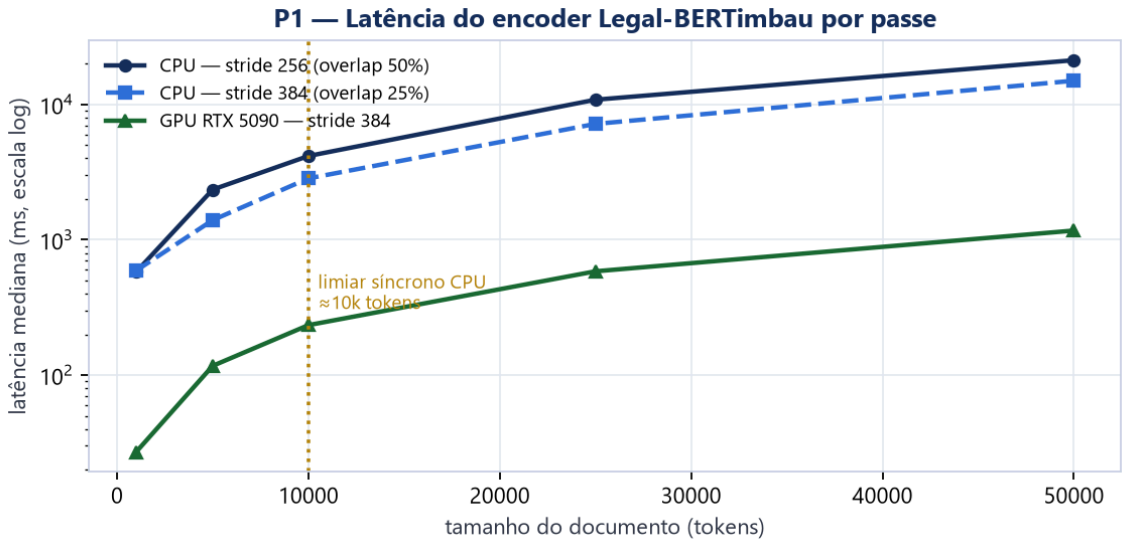
6. Validação — provas executadas e resultados

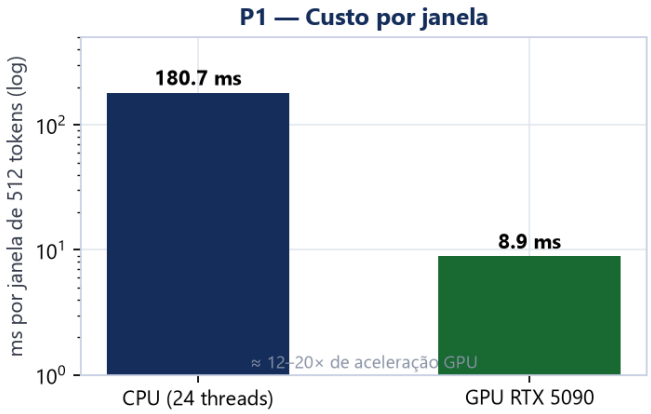
Sete spikes N1 foram executados em 16/10/2026 (artefatos em `spikes/`). Cada prova tinha hipótese falsificável e barra de aprovação pré-definida.

#	Prova	Método	Resultado
P1	Latência encoder em CPU	Legal-BERTimbau-base 109M, janelas 512, docs 1k–50k tokens, batch=1	**PROVADO** ~110–180ms/janela; doc 10k ≈ 3–4s por passe; doc 50k ≈ 15–21s → **síncrono ≤~10k, batch DEFINIDO acima**
P1b	Mesmo em GPU	RTX 5090, torch cu128	**PROVADO** ~9ms/janela (12–20×); 50k = 1,75s → síncrono universal; decisão de hardware do edge

			vira trade-off institucional
P2	Isolamento `internal:true`	Compose mínimo; probe de egress HTTP/DNS/ICMP/IPv6 + intra	**PROVADO** zero egress medido; intra-rede ok; DNS embutido resolve containers e recusa upstream (sem túnel DNS)
P3	Motor simbólico de correferência	~300 linhas de regras; 30 casos artesanais, 40 asserções	**100%** — papel, apositivo, discurso, pronome+genero, possessivo, parentesco, honorífico, anti-merge; ambíguos/catáfora **não** vinculam (conservador). ≥0,90 plausível, corpus decide
P4	Hash-chain + âncora externa	simula adulteração parcial e rewrite total	**PROVADO** — rewrite total **só** é pego pela âncora; emenda justificada por demonstração
P5	HMAC por caso	HMAC(e‖c) × HMAC(e); destruição de K	**PROVADO** zero correlação transversal; pós-destruição nenhum HMAC reproduzível — oráculo de dicionário morre
P6	Normalização Unicode	NFKC + invisíveis + homoglifos + traços; 19 baterias adversariais	**19/19** — **achado real**: NFKC não dobra U+2011→"-"; tabela de traços fechou o bypass de regex
P7	Auth offline (JWKS cache)	Keycloak 26.4 dev-mode; client_credentials; JWKS em disco	**PROVADO** RS256+iss+exp validados sem IdP; TTL 120s; adulterado e issuer-falso rejeitados

> **Decisões destravadas pela evidência:** batch assíncrono (INDEFINIDO → DEFINIDO acima de ~10k tokens em CPU); stride 384 economiza ~30% (input para a regra de merge); normalização exige tabela de traços além do NFKC; regra 1×1 nome-solto×papel-anônimo candidata ao motor oficial.

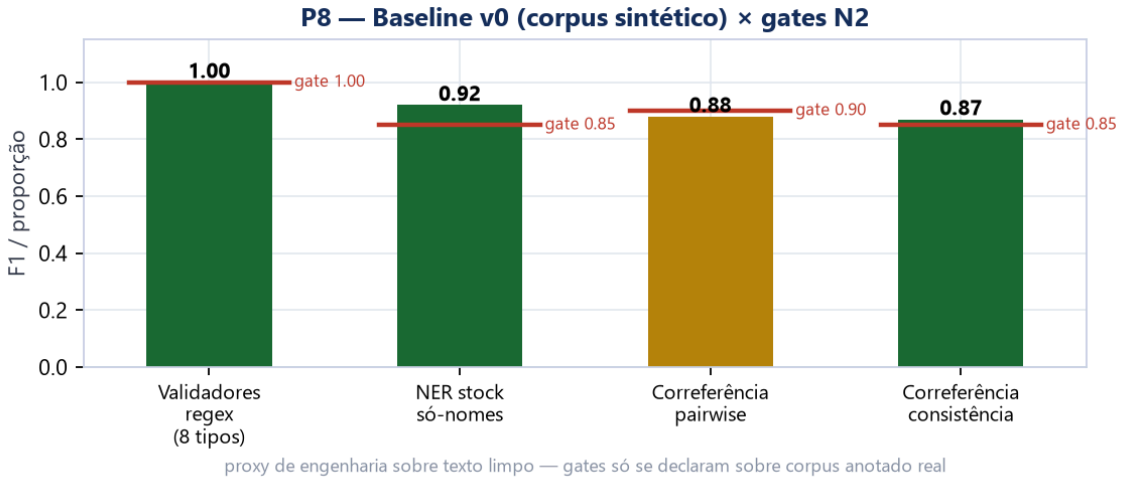




6.1 Baseline de métricas — P8 (corpus sintético v0)

O harness `spikes/p8_metricas.py` implementa as fórmulas pré-registradas de `docs/metricas.md` e mede os três componentes reais sobre `corpus_v0.jsonl` (36 docs por template, 252 entidades gold, offsets em caracteres):

Componente	Medido	Gate N2	Leitura
Validadores regex (8 tipos)	F1 = 1,00	~1,00	caso limpo resolvido; recall sob ruído OCR é o teste real (E9, corpus degradado)
NER stock LeNER-Br — só nomes	F1 = 0,92 (R=1,00)	≥ 0,85	coverage de nomes já total no proxy — fine-tune foca tagset próprio e ruído, não detecção básica
Correferência — pairwise F1	0,88	≥ 0,90	abaixo do gate por 2 pontos; o corpus expôs falha real (apositivo pós-parentesco) — corrigida, F1 subiu 0,80→0,88
Correferência — consistência/entidade	0,87	≥ 0,85	acima do gate



Escopo: proxy de engenharia sobre corpus sintético de templates — piso de dificuldade, não validade externa. O que já ficou provado estruturalmente: a divisão de trabalho híbrida do ADR-0001 aparece na medida (NER cobre nomes;

papéis/pronomes são domínio do motor simbólico), e o gap ao gate de correferência está quantificado com classes de falha identificadas.

7. Riscos e limitações honestas

Risco	Severidade	Mitigação no desenho
Correferência no long tail real (anáfora distante, OCR ruim, plural de papel, orações intercaladas)	Alta	P3 mostrou expressividade; corpus adversarial E9 decide; `review_flags` absorve o residual conservador
Validade externa (corpus sintético × documentos reais)	Alta	amostras reais autorizadas — dependência externa, pedir cedo; métricas declaradas com escopo se negadas
NER F1 no tagset próprio	Média	ciclo normal de pesquisa; validadores regex cobrem identificadores estruturados independentemente
Latência no hardware do edge (24 cores no spike)	Média	re-rodar P1 no alvo; GPU no edge é opção medida (5,3s em 50k ×3 passes)
Operação humana de chaves (unseal, cerimônias)	Média	ADR-0012 prescreve quórum distribuído; validação em N3
Insider com acesso legítimo (break-glass abusivo)	Média	endpoint ainda INDEFINIDO — exige desenho com jurídico: quatro-olhos, janela curta, justificativa na própria hash-chain

8. Trabalho restante e roadmap

A — Decisões de papel (rápido, sem código)

Item	Desbloqueia
Tagset + esquema de anotação	corpus e todas as métricas
Regra de merge de spans do janelamento	corpus avaliável (dado novo: stride 384)
Fórmula `residual_score` + recall de correferência	contrato de risco (pré-registro E1)
Política de pseudônimos + break-glass	utility score, `/v1/reversal` — **com jurídico**
Modelo de relações sujeito↔sujeito	coerência processual (P3 validou o formato REL)
Redis × rate limit em memória	compose de referência
Emendas de registro: batch/limiar/GPU	ADR-0003/0008

B — Validação científica N2 (E3–E10)

Corpus sintético → fine-tune → gates de CI: F1 NER ≥ 0,85 · correferência ≥ 0,90 + recall · reidentificação ≤ 5% · utility ≥ 0,85 (TAB adaptado) · latência-alvo pré-registrada.

C — Validação institucional N3 (E11)

TI do órgão sobe o compose sozinho; cerimônia de unseal por papéis distintos; avaliação de utilidade por usuários; medição de validade externa nas amostras autorizadas — **iniciar o pedido de autorização imediatamente** (maior lead time do projeto).

9. Inventário documental

Arquivo	Conteúdo
`docs/especificacao-tecnica.md`	especificação v1.x com emendas (12 estágios, RNFs, contrato)
`docs/adr/0000–0012`	13 decisões com contexto, alternativas e emendas datadas
`docs/arquitetura-interativav1.3.html`	visualização interativa — 12 estágios, 13 ADRs, anéis de defesa, stack, riscos
`docs/plano-de-validacao.md`	checklist N1/N2/N3 com barras falsificáveis (4/6 N1 fechados ao estado atual)
`docs/relatorio-validacao.md`	consolidado de validação (antecessor deste relatório)
`docs/metricas.md`	pré-registro das métricas: fórmulas, convenções de span, gates N2 — mudança exige emenda datada
`spikes/`	P1–P8: scripts executáveis, dados brutos (.jsonl), resultados (P*_resultado.md), artefatos P2 (compose+probe), corpus_v0.jsonl + gerador

---

Relatório gerado em 16/10/2026 a partir do estado real do repositório — documentos e artefatos citados existem e são verificáveis. Nenhuma afirmação de métrica científica (F1, correferência em corpus, reidentificação, utility) consta como atingida; constam como metas pré-registradas com trilha definida.