Relatorio de avaliacao - motor de anonimizacao

Projeto iSACI (PIDE/FAPESPA) - avaliacao de configuracoes para a porta MotorIA da esteira de anonimizacao soberana. Corpus sintetico pt-BR juridico-administrativo; execucao local via Ollama, GPU dedicada, temperatura 0.

ESTE DOCUMENTO REPORTA UMA POC. Os resultados sao proxies de engenharia sobre corpus sintetico e NAO estabelecem validade externa nem aptidao de producao.

DESVIO DA ADR-0011: a ADR-0011 define processamento deterministico/discriminativo local; a cascata avaliada usa LLM GENERATIVO local (qwen2.5) para extracao de spans e de nomes. Justificativa do experimento: medir se um LLM local disponivel fechava o recall residual onde a camada deterministica falhava, antes de investir em treino. Condicao de retorno a ADR: substituir o componente generativo por discriminativo treinado (ex.: NER LeNER-Br/UlyssesNER-Br), medido contra o mesmo gate na particao teste. A decisao de aceitar o desvio e do requisitante, nao desta POC.

Distancia da especificacao: a especificacao preve NER legal-BERT com cofre criptografico e guardrails; a cascata e um proxy de engenharia que nao implementa esses componentes.

1. Corpus de avaliacao

particao	documentos	entidades	alvos (priv)	preservadas
ajuste (tuning)	30	241	123	118
teste (held-out)	80	665	360	305

Tipos anonimizaveis: NOME, CPF, EMAIL, TELEFONE, RG, ENDERECO. Preservados: ORGAO, CARGO, CIDADE, INSTITUICAO, CNJ, VALOR. INSTITUICAO tem amostra pequena (4 ajuste / 10 teste) - conclusoes por tipo nao sao suportadas.

Declaracao: corpus integralmente sintetico/fabricado; gabaritos JSON com offsets sobre o TXT; PDFs regenerados com wrap seguro (sobrevivencia de extracao 241/241 e 665/665).

2. Ambiente e versoes

- Ollama 0.40.5 em localhost:11434; GPU NVIDIA RTX 5090 Laptop (~24 GB); temperature=0; num_ctx=1024.

- Modelos: qwen2.5:7b (digest 845dbda0ea48ed74...), qwen2.5:14b (7cdf5a0187d5c58cc5d369b255592f7841d1c4696d45a8c8a9489440385b22f6).

- Prompts: v0 sha256 644cac43... (1100c, congelada); v1 cf92a61d... REJEITADA; contrato-spans-v0 7d7ac2b2...; contrato-cascata-nome-v0.

3. Configuracoes avaliadas na ajuste

#	configuracao	recall agregado	status
0	DemoMotorIA (regex)	baseline	referencia
1	qwen2.5:7b + v0 (texto->texto)	98/123 (79.7%)	baseline LLM
2	qwen2.5:7b + v1 (endereco/fone)	113/123 (91,9%)	REJEITADA
3	qwen2.5:14b + v0	106/123 (86.2%)	regressao parcial
4	qwen2.5:7b + spans-v0 (JSON)	105/123 (85.4%)	gate falhou
5	cascata (det + 2x LLM + guarda)	ajuste: 123/123 (tuning); teste: 356/360 (98,9%)	candidata

v1 rejeitada: regressao NOME/CPF/RG, mutacao de texto preservado (Santarem->Santarem com acento) e tag fora do padrao em 2 documentos - a rejeicao deve-se a regressao e a mutacao, NAO ao agregado (que subiu). 14B melhorou ENDERECO/TELEFONE mas regrediu NOME/CPF/RG - evidencia de que escala de modelo nao e monotonica.

4. Gate na particao teste (cascata)

80 documentos cegos; desenho congelado apos a ajuste. Camadas: detectores deterministicos (CPF, RG, email, telefone, endereco) -> spans LLM -> segunda passada LLM so nomes -> guarda de zona protegida (CNJ/VALOR) -> substituicao por codigo.

tipo	recall	excesso preservados
NOME	97/101 (96.0%)	-
CPF	65/65 (100%)	-
EMAIL	57/57 (100%)	-
ENDERECO	44/44 (100%)	-
RG	32/32 (100%)	-
TELEFONE	61/61 (100%)	-
AGREGADO	356/360 (98.9%)	0/305

Excesso em preservados: denominador = 305 entidades preservadas do gabarito (ORGAO 73, CARGO 40, CIDADE 41, CNJ 70, VALOR 71, INSTITUICAO 10). O '278' da versao anterior era erro de denominador - o excesso medido e 0 sobre as 305.

nivel NER	P	R	F1	gate	veredicto
exact (ini,fim,tipo)=gold	0.780	0.731	0.755	>= 0.85	FAIL
overlap (>=1 char,tipo)	0.970	0.908	0.938	-	referencia

NER exact por fonte	TP	FP	FN	P	R	F1
so det (deterministico)	180	22	180	0.891	0.500	0.641
so llm (spans+so-nomes)	83	52	277	0.615	0.231	0.335
uniao (cascata)	263	74	97	0.780	0.731	0.755

tipo	det: candidato pre-merge	det: aceito pela cascata	llm: aceito
CPF	65/65 (100%)	36/65 (55%)	-
EMAIL	57/57 (100%)	56/57 (98%)	-
ENDERECO	38/44 (86%)	35/44 (80%)	-
RG	32/32 (100%)	16/32 (50%)	-
TELEFONE	61/61 (100%)	59/61 (97%)	-
TOTAL det (5 tipos)	253/259 (97,7%)	202/259 (78,0%)	-
PESSOA	-	-	97/101 (96%)

97,7% e o recall POTENCIAL do deterministico sobre candidatos pre-merge (recomputado sem motor); o recall entregue pela cascata via spans dessa fonte e a coluna 'aceito pela cascata' (202/259 = 78,0%) - a diferenca sao spans det descartados no merge em favor de spans llm sobre-estendidos (mesclar() guarda UMA fonte por span). Cobertos por ambos: CPF 29, RG 16, ENDERECO 3, TELEFONE 2, EMAIL 1. O llm sobre PESSOA e limite inferior - seus candidatos que perderam o merge nao sao registrados. O recall ENTREGUE por tipo (uniao das fontes) permanece o da tabela principal acima.

FP por tipo declarado	det:	llm:
CPF	8	25
RG	14	15
ENDERECO	0	5
PESSOA	0	3
TELEFONE	0	2
CEP (inventado)	0	2

TOTAL	22	52

Top-10 FP do llm: por tamanho de span, com o padrao:

```
ENDERECO  [prosa+rotulo+nome (203c)] IVONETE CRISTINA ROCHA, inscrito no RG sob o n. 58.320.829, inscrito(a
RG        [prosa+nome+2 entidades (169c)] Francisca Ferreira, RG n. 18.338.687-7, CPF 73358622991, Endereco: Rua
CPF       [rotulo+nome (59c)] DENISE PINHEIRO, inscrito(a) no CPF sob o n. 448.502.234-00
ENDERECO  [fronteira+CEP (59c)] Rua dos Mundurucus, 2580, Centro, Maraba-PA, CEP 68482-331.
RG        [rotulo+nome (58c)] Francisca De Oliveira Lima, portador(a) do RG 59.798.381-2
RG        [rotulo+nome (52c)] Pedro De Souza, inscrito no RG sob o n. 30.677.315-X
ENDERECO  [fronteira+cidade-UF (46c)] Tv. Castelo Branco, 1674, Nazare, Castanhal-PA
ENDERECO  [fronteira+cidade-UF (44c)] Tv. Castelo Branco, 690, Reduto, Santarem-PA
ENDERECO  [fronteira+cidade-UF (44c)] Tv. Castelo Branco, 1491, Sao Bras, Belem-PA
CPF       [rotulo+nome (43c)] IVONETE CRISTINA ROCHA, CPF 204.306.939-07.
```

Leitura corrigida da atribuicao por camada: nos tipos sob sua responsabilidade o det: cobre 253/259 (97,7%) - unica lacuna real: ENDERECO sem CEP (6). Dos 74 FP exact, 52 sao do llm: (sobre-extensao: rotulo + prosa + fronteira) e 22 do det: (rotulo 'RG ' dentro do span; regex de CPF casando telefone de 11 digitos). A atribuicao do exact F1 por camada: a fronteira frouxa do llm: e o maior contribuinte de FP, mas a afirmacao 'o llm derruba o F1' e simplista - isolado, det F1=0,641 e llm F1=0,335, ambos abaixo de 0,85; os FP do det (rotulo no span, confusao CPF/telefone) tambem precisam de correcao.

metrica pre-registrada	resultado	gate	veredicto
reidentificacao (mencao)	4/360=0,0111 IC95%[0,4-2,8%]	<= 0.05	PASS robusto
reidentificacao (documento)	4/80=0,050 IC95%[2,0-12,2%]	<= 0.05	limite dentro do IC
coreferencia pairwise F1	-	>= 0.90	nao avaliado*
coreferencia anti-merge	-	<= 5% pares	nao avaliado*
consistencia por documento	-	>= 0.85	nao avaliado*
utility (TAB adaptado)	-	>= 0.85	nao avaliado**
latencia (contrato API)	-	a fixar	nao avaliado

* corpus v0 nao anota ent_id (cluster de correferencia) - pairwise, anti-merge e consistencia nao sao computaveis. ** utility TAB exige checklist humano e decisao juridica de pesos (metricas.md sec.5); latencia tem barra a fixar no hardware-alvo.

Reidentificacao em duas unidades: por mencao 4/360 = 1,1% (Wilson 95%: 0,4%-2,8%); por documento 4/80 = 5,0% (Wilson 95%: 2,0%-12,2%). O PASS do gate <=0,05 e robusto na unidade de mencao (limite fora do intervalo) e NAO e robusto na unidade de documento - 5,0% esta dentro do intervalo. Unidade de risco para LGPD: o DOCUMENTO - um documento com qualquer nome residual sai com dado pessoal identificavel; a unidade por mencao dilui o risco em documentos com muitas entidades.

NER exact reprova por precisao de fronteira: spans LLM sobre-estendidos comem rotulos ('RG ', 'CPF n. ', prosa conectiva) - e o mesmo comportamento medido pela divergencia de fidelidade (44/80 docs), sem vazamento adicional. Excesso sobre nao-entidade: 419c de rotulo + 59c de prosa conectiva em 43/80 docs; zero conteudo substantivo perdido (inspecao manual de 6 documentos; nao e metrica automatica).

excesso por gravidade	spans	chars fora de gold
a) rotulo curto (span <=20c)	38	142
b) prosa conectiva (span 21-100c)	21	216
c) span >100c (dano alto)	2	120
TOTAL	61	478

Faixa (c) - duas leituras lado a lado: (i) spans com excesso fora de gold acima de 100 caracteres: 0; (ii) spans com tamanho total acima de 100 caracteres: 2. A faixa (c) usa a leitura de tamanho total, por medir contexto removido do documento; na leitura de excesso fora de gold nenhum span entra nessa faixa.

Faixa (c), inspecionada:

```
doc-0057 llm1:ENDERECO 203c: 'IVONETE CRISTINA ROCHA, inscrito no RG sob o n. 58.320.829, inscrito(a) no CPF sob o n. 732.590.332-46,
```

```
reside...'
    motivo: clausula de atribuicao inteira: nome + rotulos + RG + CPF + 'reside'
  doc-0102 llm1:RG 169c: 'Francisca Ferreira, RG n. 18.338.687-7, CPF 73358622991, Endereco: Rua dos Mundurucus, 440, ...'
    motivo: nome + RG + CPF + endereco num unico span
```

Atencao de utilidade: substituir os spans da faixa (c) remove CONTEXTO do documento (clausula de atribuicao, sequencia nome+documento+endereco), nao apenas o dado pessoal - e o erro que a metrica utility TAB (nao avaliada) mediria.

Vazamentos (reident): 4 nomes - doc-0051, doc-0066, doc-0078 ('Pedro Henrique Almeida') e doc-0080 ('MARCOS AURELIO TAVARES'). Modo de falha unico: a passada so-nomes omite uma pessoa quando o documento tem varias. Falhas de JSON: 2/160 chamadas (sem impacto - camada deterministica cobriu).

5. Metodo e interpretacoes declaradas

- gold = entidades com preservar=false (PRIV); preservadas = preservar=true.

- Mapa de tipos para o tagset de metricas.md: NOME->PESSOA, CNJ->PROCESSO_CNJ; demais nomes identicos. Tipos inventados pelo modelo (CEP, PROCESSO) mantidos como estao - contam FP.

- Entidade = cada ocorrencia plantada; o corpus nao anota ent_id, logo reident conta por mencao (a unidade por documento e reportada em separado como unidade de risco).

- Preditos = spans aceitos e mesclados do eval_cascata, com fonte det:/llm: convertida em tipo.

- O NER span-level agrega as duas camadas (det: e llm:) na tabela principal; a separacao validador-deterministico x NER exigida por metricas.md sec.2 esta na tabela 'NER exact por fonte' (secao 4).

- Excesso sobre nao-entidade: caracteres de spans preditos fora de qualquer span gold; 'rotulo' vs 'conteudo' por classificacao de fragmento - conteudo inspecionado manualmente (6 docs), nao e metrica automatica.

6. Gate de residual PII (salvaguarda POC)

app/pii_residual.py - padroes deterministicos sobre a saida do motor (CPF, RG, email, telefone, nome em contexto: intimad[oa]/em face de/servidor(a)). Em processar_evento: residual > 0 -> falha_anonimizacao:{id}:residual_pii na trilha, nada vai ao bucket anonimizado, nenhum doc_anonimizado; log com contagens, nunca valores.

Testes: 27 unitarios (positivos por tipo, negativos de CNJ/valor/cargo/orgao/cidade, e2e com bucket vazio e trilha de falha). Suite completa verde. Na ajuste: 0 disparos em 30 saidas (1 FP corrigido - 'Caixa Economica Federal' entrou na lista de nao-pessoa).

Nota sobre xfails: os 4 xfails da suite (CPF sem pontuacao, nome livre sem rotulo, endereco livre, telefone sem hifen) referem-se ao regex ISOLADO do DemoMotorIA, nao a cascata - na cascata esses casos passaram.

Avaliacao na teste: o gate NAO foi avaliado na particao teste como salvaguarda. Aplicacao pos-hoc sobre as 4 saidas com vazamento: dispararia em 3 dos 4 documentos (contextos 'em face de' e 'servidor') - nao e avaliacao da salvaguarda; o 4o ('intimado(a)') esta fora do formato coberto - o padrao aceita '(s)', nao '(a)'.

7. Declaracoes

- O desenho da cascata foi definido APOS observar falhas da particao ajuste; a teste e held-out, mas o desenho carrega conhecimento da ajuste.

- Os padroes de contexto do gate foram definidos apos observar falhas da ajuste e NAO sao validados como cobertura de nomes; o gate NAO garante ausencia de PII.

- Corpus sintetico/template: resultados sao proxies de engenharia; documentos reais (OCR, digitalizados, novos formatos) podem degradar as metricas.

- INSTITUICAO: amostra insuficiente (4+10) para conclusao por tipo.

8. Trabalho futuro

Curto prazo (motor):

- Aparar rotulos/fronteiras dos spans por codigo antes de substituir - recupera NER exact F1 sem tocar no recall e melhora a fidelidade de contexto.

- Retry da passada so-nomes em JSON invalido (2/160) e segunda passada de verificacao sobre a saida - ataca o modo de falha observado (omissao de 1 pessoa em documento com varias).

- Gate congelado: qualquer mudanca futura de modelo, prompt ou regex mede-se contra a particao teste, nunca contra a ajuste.

Medio prazo (cobertura e qualidade):

- NER discriminativo treinado (LeNER-Br / UlyssesNER-Br + encoder tipo BERT) como detector de nomes - a resposta arquitetural correta para extrator deterministico-auditavel, alinhado a ADR-0011.

- Avaliar qwen2.5:32b apenas na passada so-nomes (cabe nos 24 GB) para isolar capacidade vs contrato.

- Corpus real autorizado e anotado - os gates (F1>=0.85, reident<=0.05) so sao declarados cumpridos sobre corpora reais.

- Documentos digitalizados/OCR na avaliacao - modo de falha nao coberto pelo corpus textual.

Plataforma (independente do motor):

- mTLS inter-nos (planejado), assinatura de envelope e verificacao de integridade fim a fim.

- RBAC por caso_cnj, cofre de chaves e rotacao.

- Runbook de falha_anonimizacao: triagem residual_pii x saida_ilegivel, reprocessamento manual supervisionado.

- Dashboard de metricas (detectadas/residuais/substituidas) com alerta de drift em producao.

- Custo/latencia: 2 chamadas LLM por documento (~1.6s/doc em 7B) - orcar fila e throughput antes de piloto.

Dependencias de decisao (ata de alinhamento da arquitetura - nao medidas nesta POC):

- Cofre de chaves nasce na Etapa 4/5, nao na 7 - o mapeamento pseudonimo->nome real comeca no primeiro documento de cada caso; e dependencia da correferencia (Etapa 5) e da pseudonimizacao, upstream do motor, nao item generico de plataforma.

- Reidentificacao (decisao juridica aberta): quem pode pedir, quem autoriza e se o cofre e obrigatorio - define se o modo e anonimizacao irreversivel ou pseudonimizacao reversivel, e afeta a leitura do reident <=0,05 (reidentificavel por quem?).

- Exclusoes de processo (aberta): segredo de justica, ECA, violencia domestica - categorias que definem o escopo do corpus real da Etapa 3.

- Irreversibilidade do HMAC (aberta): com a chave no servidor, um atacante com acesso ao banco pode testar candidatos e reverter pseudonimos; o modo so e irreversivel com a chave destruida?

- Registros de supressao (aberta): review_flags e spans suprimidos podem guardar trechos? O gate de residual desta POC ja loga so contagens - alinhado, mas a decisao de conteudo dos registros esta pendente.

- Etapa 6 (higienizacao/guardrails): o texto diz que precede a anonimizacao, o cronograma a agenda depois da Etapa 5 - conflito registrado na ata, sem decisao.

- Mapa POC->cronograma: esta avaliacao cobre Etapa 3 (corpus) e parte da 4 (NER); correferencia (Etapa 5), higienizacao (6), auditoria/cofre (7) e utility TAB (10-11) seguem pendentes; Etapa 11 depende de CEP/TCLE, ausentes do cronograma.

Recomendacao: manter a cascata como candidata de POC, nao aprovada para producao, dado que o gate NER exact (0,85) falhou; manter o gate de residual ativo. Reavaliar apos correcao de fronteira, corpus real e piloto supervisionado.

9. Reprodutibilidade

Seed do gerador de corpus: 20261020. Todas as medicoes em 2026-10-20 (timestamps dos artefatos): v0 ajuste 15:23; v1 15:43; 14B 15:56; spans-v0 16:01; cascata ajuste ~16:28; cascata teste ~16:49; metricas pre-registradas e gate de residual na mesma sessao.

sha256sum dos artefatos de codigo (saida literal):

```
3cd8dc1ce6d2142fdbda192ea4e75a22e81e1fdf771c67cc4316200c674f4656 *scripts/gerar_corpus.py
085609ac0ff8d9ad14e26f624385deb33d1a31ffeaa24fcff83291b4da05e870 *scripts/eval_ollama_ajuste.py
507a2d2a315f0bd5eb8a3f1002bc5756eb29920d22e3327aabb8e538565b65db *scripts/eval_ollama_prompt.py
0082c7404bcd0a2b1b9d18d94de6826e4d470305c202340856a26994fec0c097 *scripts/eval_spans.py
84cea94c28c290424372869c2a4a11e65452c6005561a8faab0811c139aa93c4 *scripts/eval_cascata.py
92394e90518062b67dbe2cdab8fe6e882a418c877b787a2c873ebef6daad2506 *scripts/metricas_prereg.py
be38a6de5ff90f6a6e16d6b1bd24edcf409bea577a93493f41dbfff95f8ea202 *scripts/painel.py
d30fa82aa34787263b2c566d1995fdddb63528a0f79b76505c15c475bfbaeb22 *scripts/fidelidade.py
76f1d90369fd2d0e5770729ad4176c080a62a84f1b4286b6106384329821de0d *scripts/analisar_extracao.py
9046bdddcdae60ad2bd6dd89daa27a9df0a3075f18f564b25d2797b0b2af8dfe *app/pii_residual.py
955d472f24f2467349285b1bc8d7e746b21f724bf1981f55eadf1a0206b4275c *app/worker.py
```

Comandos de execucao (reconstruidos do historico; marcados quando nao verificados):

```
python scripts/gerar_corpus.py  (reconstruido, nao verificado)
python scripts/eval_ollama_ajuste.py  # v0+7B ajuste (reconstruido, nao verificado)
python scripts/eval_ollama_prompt.py  # v1+7B ajuste (reconstruido, nao verificado)
IA_MODEL=qwen2.5:14b python scripts/eval_ollama_prompt.py  # 14B (reconstruido, nao verificado)
python scripts/eval_spans.py  # spans-v0 (reconstruido, nao verificado)
IA_MODEL=qwen2.5:7b python -X utf8 scripts/eval_cascata.py corpus ajuste  (reexecutado nesta sessao: reproduziu 123/123 e 0 excesso)
IA_MODEL=qwen2.5:7b python -X utf8 scripts/eval_cascata.py corpus teste  (executado nesta sessao; NAO reexecutado de forma independente)
python -X utf8 scripts/metricas_prereg.py corpus teste saidas_ollama_cascata_teste  (verificado)
python -X utf8 -m pytest tests/ -q  (verificado)
```

Reexecucao: a particao ajuste foi reexecutada no mesmo ambiente e modelo e reproduziu 123/123 alvos e 0 excesso em preservados; a particao teste nao foi reexecutada de forma independente. Isso demonstra determinismo local, nao reprodutibilidade em outro ambiente.